

ttaohe

✉ ttaohe828@gmail.com | 🌐 github.com/ttaohe | 🌐 ttaohe.github.io

教育经历

武汉大学 计算机应用技术 硕士	2023.09—2026.07
西北工业大学 电子信息工程 本科	2019.09—2023.07

工作经历

Infinigence AI 全职 LLM Inference Infrastructure	2026.06—至今
Ant Group 实习 LLM Inference Infrastructure	2026.05—2026.09
Xiaomi 实习 On-device Inference Infrastructure	2025.12—2026.03

技术能力

工作方向：大模型推理基础设施、KV Cache 与分层缓存；具备端侧推理基础设施实践经验。

项目经历

1. MLA L2 Host Cache Deduplication

针对张量并行场景下的 Host 缓存重复问题，由 TP0 进行**真实 Host 内存注册**，其他 TP rank 采用占位注册；由 TP0 完成 **Radix Tree 匹配**及 L2 到 L1 的缓存加载，再向其他 rank 广播。

个人总结

博观而约取，厚积而薄发。

苏轼《稼说送张琥》